Examen 1 de Reconocimiento de Patrones

Nombre: Amaya Soria Angel Alberto

Expediente: 223210350

$a = 0, \qquad b = 5$

Semilla aleatoria: 223210350

Problema 1

Problema 1 – Teoría de equidad e imposibilidad

En lo que sigue $Y = 1$ significa que el cliente incumplió, $Y = 0$ que pagó, y $\hat{Y} = 1$ que el banco rechazó el crédito. Para un grupo $G = g$ escribimos $p_g = P(Y = 1 \mid G = g)$, $PPV_g = P(Y = 1 \mid \hat{Y} = 1, G = g)$, $FPR_g = P(\hat{Y} = 1 \mid Y = 0, G = g)$ y $FNR_g = P(\hat{Y} = 0 \mid Y = 1, G = g)$.

(a) La identidad del FPR

Escribimos $P(\hat{Y} = 1, Y = 0)$ de dos formas. Condicionando sobre Y,

$$P(\hat{Y} = 1, Y = 0) = P(\hat{Y} = 1 \mid Y = 0)\, P(Y = 0) = FPR\,(1 - p).$$

Condicionando sobre $\hat{Y}$,

$$P(\hat{Y} = 1, Y = 0) = P(Y = 0 \mid \hat{Y} = 1)\, P(\hat{Y} = 1) = (1 - PPV)\, P(\hat{Y} = 1).$$

Análogamente para los incumplidores rechazados,

$$\begin{aligned} P(\hat{Y} = 1, Y = 1) &= P(\hat{Y} = 1 \mid Y = 1)\, P(Y = 1) = (1 - FNR)\, p \\ &= P(Y = 1 \mid \hat{Y} = 1)\, P(\hat{Y} = 1) = PPV\, P(\hat{Y} = 1). \end{aligned}$$

Dividiendo la primera expresión entre la segunda se cancela $P(\hat{Y} = 1)$ (suponiendo que se rechaza a alguien) y se obtiene

$$FPR = \frac{(1 - PPV)\, P(\hat{Y} = 1)}{(1 - p)} \quad \text{y} \quad (1 - FNR)\, p = PPV\, P(\hat{Y} = 1),$$

de modo que

$$FPR = \frac{p}{1 - p} \cdot \frac{1 - PPV}{PPV} \cdot (1 - FNR)$$

La identidad es puramente algebraica: no es una coincidencia empírica, sino una consecuencia de usar la misma matriz de confusión. En la práctica sirve para verificar que una tabla por grupo es internamente consistente.

(b) Igualar FPR, PPV y FNR es imposible con tasas base distintas

El enunciado pide comparar dos grupos A y B con $FPR_A = 0.30$ y $FPR_B = 0.175$. Si se quisiera igualar además la PPV y el FNR, la identidad del inciso (a) daría un valor requerido de $PPV_B = 7/19 \approx 0.368$. El caso general muestra que eso no puede funcionar cuando las tasas base difieren.

Supongamos que el PPV y el FNR son los mismos en ambos grupos, con $p_A \neq p_B$. Igualar el FPR exige

$$\frac{p_A}{1 - p_A} \cdot \frac{1 - PPV}{PPV} \cdot (1 - FNR) = \frac{p_B}{1 - p_B} \cdot \frac{1 - PPV}{PPV} \cdot (1 - FNR).$$

Como $p_A \neq p_B$, los factores $p/(1 - p)$ son distintos. Para que la igualdad pueda cumplirse debe ser

$$(1 - PPV)(1 - FNR) = 0.$$

Es decir, hay dos únicas salidas: $PPV = 1$, que significa que no hay falsos positivos (y por tanto $FPR = 0$ en ambos grupos), o $FNR = 1$, que significa que nunca se predice positivo, en cuyo caso la PPV queda indefinida porque no hay rechazos. Por eso la frase del enunciado "no perfecto" debe leerse como "comete falsos positivos": el teorema no dice que no exista un clasificador justo en sentido absoluto, sino que un clasificador con algún falso positivo no puede igualar las tres métricas a la vez con tasas base distintas. Vale la pena observar por separado el caso $PPV = 1$ con $FNR > 0$: allí nunca se rechaza a un cliente que iba a pagar, pero sí se aprueban algunos que incumplen; es un clasificador selectivo en el rechazo, no perfecto. El clasificador perfecto es el caso extremo $FPR = FNR = 0$ y $PPV = 1$, que sí iguala todas las métricas trivialmente porque no comete ningún error. Fuera de ese caso límite y de los degenerados, la imposibilidad entra en juego.

(c) Calibración y los errores por grupo

El enunciado plantea dos supuestos: (P1) la calibración por grupo, $P(Y = 1 \mid S = s, G = g) = s$, donde S es el puntaje, y (P2) la ley de probabilidad total. Entonces

$$E[S \mid G = g] = E\big[E[Y \mid S, G] \mid G = g\big] = E[Y \mid G = g] = p_g,$$

porque $E[Y \mid S, G] = P(Y = 1 \mid S, G) = S$ bajo (P1). Es decir, un puntaje calibrado tiene media igual a la tasa base de su grupo: su comprobación numérica es una prueba de calibración.

El ejemplo del enunciado toma $p_A = 11/25 = 0.44$ y $p_B = 13/50 = 0.26$, y considera rechazar exactamente a quienes tienen $S = 0.8$, cuyo PPV es 0.8 por calibración. Aplicando la identidad se obtiene

$$FPR_A = \frac{1}{7} \approx 0.143, \qquad FNR_A = \frac{3}{11} \approx 0.273,$$
$$FPR_B = \frac{1}{37} \approx 0.027, \qquad FNR_B = \frac{9}{13} \approx 0.692.$$

Con el criterio FPR sale más perjudicado el grupo A, porque se rechaza a una fracción mayor de quienes no incumplen; con el criterio FNR sale más perjudicado el grupo B, porque se aprueba a una fracción mayor de quienes sí incumplen. Ninguna de las dos lecturas es la "correcta": cada una prioriza un tipo de error, y con puntajes calibrados y tasas base distintas no pueden coincidir.

(d) Por qué el umbral óptimo es el mismo para todos

Dar crédito a un cliente con puntaje calibrado s produce una ganancia esperada

$$(1 - s)G - sL.$$

Esta cantidad es positiva si y solo si $(1 - s)G > sL$, es decir, si y solo si

$$s < \frac{G}{G + L}.$$

Con $L = 5G$ el umbral es $\frac{G}{G+5G} = 1/6$. El umbral no depende del grupo: por calibración, $P(Y = 1 \mid S = s, G = g) = s$ en cada grupo, así que el cálculo esperado es el mismo para un hombre y para una mujer con el mismo puntaje. Pero por el inciso (b), aplicar el mismo umbral con tasas base distintas ($p_H \neq p_M$) conduce a FPR y FNR distintas. La ganancia óptima y la igualdad de errores son objetivos distintos: el primero sugiere un solo umbral, el segundo exige en general umbrales distintos o intervenir de otra forma.

(e) Tú decides: definición, umbrales y uso del atributo

Tú decides. Definición elegida: igualar el FPR, porque es la diferencia entre grupos que el bootstrap de 05 distingue del ruido (0.042289, IC 95 % $[0.020183, 0.064465]$, sin el cero), mientras que la diferencia de FNR es compatible con cero (-0.023922, IC 95 % $[-0.064162, 0.015438]$). En la cuadrícula 0.05–0.60 con tolerancia 0.01, el par de máxima ganancia fuera de muestra es $(t_H, t_M) = (0.19, 0.18)$: igual FNR e igual FPR y FNR eligen el mismo par, así que la elección es robusta a esas variantes. Paridad demográfica y paridad predictiva se descartan como definición principal porque dejan diferencias de errores mayores (1.76 y 1.26 puntos en OOF la primera; 10.96 y -7.51 la segunda), aunque en prueba llegaron a dar ganancias mayores que la línea base ($+11$ y $+35$ unidades de G), ambas dentro del ruido. El costo de ser justo no se distingue de cero: pérdida de 7 unidades de G, IC95 % $[-100, 116]$. Con $p_H = 0.233$ y $p_M = 0.213$ la imposibilidad teórica es leve: con $(0.19, 0.18)$ las brechas quedan en FPR 0.0095, FNR 0.0078, PPV 0.016 y tasa de rechazo 0.014, así que casi todas las definiciones se cumplen a la vez. Ojo: los IC95 % de esas brechas posteriores son anchos (FPR $[-0.012, 0.031]$, FNR $[-0.034, 0.049]$), así que su compatibilidad con cero no prueba que las brechas hayan desaparecido, solo que con esta muestra ya no se distinguen del ruido.
Umbrales distintos por grupo: sí se aceptan como intervención explícita, con la condición de que se justifiquen y se auditen. El umbral de hombres es más alto (0.19 contra 0.18) porque su FPR base era mayor: no es una ventaja arbitraria, es la corrección documentada de la disparidad. No se usa la prueba para elegirlos: se eligieron con predicciones fuera de muestra del 70 % y la prueba solo reporta.
£Usar el sexo como entrada del modelo? No. El contraste de 07 reentrenó el mismo boosting con SEX y obtuvo AUC 0.779162 (prácticamente el mismo que 0.779463 sin SEX), ganancia 2019 ($+35$, $+1.76$ %), pero brecha de FPR 0.082428 e IC sin cero, y brecha de FNR significativa -0.053067. Meter el atributo protegido no elimina las diferencias, las agrava, y contradice la decisión ya registrada de dejar SEX fuera y usarla solo para auditoría. Tampoco basta con quitarlo: otras variables predicen SEX con AUC 0.650929 en CV y 0.649996 en prueba (AGE y varias PAY_* encabezan la asociación), así que SEX sigue presente en el análisis como variable de auditoría y, si se interviene, para aplicar el umbral correcto. El modelo principal se mantiene sin SEX.

Bitácora de decisiones – Problema 1

Cada decisión registra qué se decidió, qué se descartó, por qué y con qué evidencia. Las tres primeras decisiones reproducen el texto del usuario sin cambios; las tres últimas fueron redactadas por el asistente con evidencia propia y aceptadas por el alumno.

Decisión 1 – Tratamiento de códigos raros

Texto del usuario, sin cambios:

> "(a) Qué decidí: agrupar los códigos no documentados con la categoría "otros": EDUCATION 0, 5 y 6 pasan a 4, y MARRIAGE 0 pasa a 3.
>
> (b) Alternativas que descarté: eliminar esas filas del entrenamiento, o dejarlas como categorías propias (one-hot).

(c) Por qué: con boosting, las tres variantes dan el mismo AUC de validación dentro del ruido: agrupar 0.7789, eliminar 0.7780 y categorías propias 0.7788, con desviación entre particiones de ≈ 0.005 a 0.006. Como el AUC no decide, elegí la más simple y la que no pierde filas. Descarté eliminar porque quita $\approx 1.3\,\%$ de los datos sin ganancia y cambiaría la población que estoy auditando; descarté las categorías propias porque dejan columnas de 14 a 54 filas.

(d) Qué pierdo: al agrupar mezclo códigos que quizá significan cosas distintas, y que sean equivalentes a "otros" es un supuesto que no puedo verificar, porque la documentación de UCI no define esos códigos."

Evidencia: `02_decisiones_datos.ipynb` (secciones 1 y 3) y `resultados/significado_education.csv`, `significado_marriage.csv` y `decisiones_datos.csv`.

Decisión 2 – Tratamiento de PAY_0..PAY_6

Texto del usuario, sin cambios:

"(a) Qué decidí: tratar PAY_0..PAY_6 de forma distinta según el modelo. En boosting las dejo como números tal cual (codificación numérica). En regresión logística las separo en indicadores de estado (-2, -1, 0) más una variable de meses de atraso (valores ≥ 1).

(b) Alternativas que descarté: en boosting, la codificación por estados más meses de atraso; en regresión logística, la codificación numérica.

(c) Por qué: en boosting las dos codificaciones dan el mismo AUC de validación dentro del ruido (0.7789 con numérico contra 0.7782 con estados, con desviación entre particiones de ≈ 0.006); los árboles pueden cortar en -2, -1 y 0 por su cuenta, así que usé la más simple. En regresión logística la diferencia sí es real: el AUC pasa de 0.7267 con numérico a 0.7687 con estados ($+0.042$, con desviaciones de 0.003 a 0.007), porque -2, -1 y 0 son estados distintos y no una escala numérica, y la logística los trata como si lo fueran.

(d) Qué pierdo: al usar codificaciones distintas, la comparación entre modelos mezcla el efecto del modelo con el de la codificación. Además, en boosting acepto que el árbol necesite varios cortes para separar códigos que no tienen un orden numérico real, y no sé qué significan el 0 y el -2 porque la documentación de UCI no los define."

Evidencia: `02_decisiones_datos.ipynb` (secciones 1, 3 y 4) y `resultados/significado_pay_0.csv`, `significado_pay_2.csv` y `decisiones_datos.csv`.

Decisión 3 – Incluir o excluir SEX

Texto del usuario, sin cambios:

"(a) Qué decidí: SEX no entra como variable de entrada en el modelo principal. Se conserva aparte, solo como variable de auditoría para analizar los resultados por grupo.

(b) Alternativa que descarté: incluir SEX como entrada del modelo.

(c) Por qué: SEX quedó fuera porque la diferencia de AUC con y sin SEX (0.00013) es mucho menor que la variación entre particiones de validación cruzada (≈ 0.006); no aporta valor predictivo medible, así que no justifico usar un atributo protegido. (Con SEX: 0.77891; sin SEX: 0.77878, boosting, 5 particiones.)

(d) Qué pierdo: la comparación se hizo solo con boosting, no con regresión logística. Que SEX no mejore el AUC no significa que quitarla elimine las diferencias entre grupos, porque otras variables pueden funcionar como sustitutas; eso lo evalúo en el inciso (e) de la práctica. Además, para analizar equidad sigo necesitando saber el grupo de cada persona, así que el sexo no desaparece del análisis, solo del modelo."

Evidencia: `02_decisiones_datos.ipynb` (sección 5) y `resultados/decisiones_datos.csv`.

Evidencia posterior (07) – Decisión 3

Nota agregada por la libreta `07_sin_atributo.ipynb` (mismo split, mismos hiperparámetros de 03, misma calibración isotónica global, umbral 1/6). No forma parte del texto textual del usuario. Incluir SEX como entrada no elimina las diferencias; las amplía: la brecha de FPR pasa de 0.042289 a 0.082428 (+0.040, IC95 % pareado $[0.031, 0.048]$, sin el cero); la brecha de FNR pasa de -0.023922 a -0.053067 (-0.029, IC95 % pareado $[-0.042, -0.017]$, sin el cero); ΔAUC $= -0.0003$ (0.779162 con SEX frente a 0.779463 sin SEX); y Δganancia $= +35$ unidades de G $(2019 - 1984)$, IC95 % pareado $[-36, 100]$, que sí contiene el cero (dentro del ruido). Esto confirma la advertencia del inciso (d) del usuario: quitar SEX del modelo no elimina las diferencias entre grupos (otras variables predicen SEX con AUC 0.650929 en CV y 0.649996 en prueba), y meterla como entrada las agrava. La decisión de dejar SEX fuera del modelo principal se mantiene.

Decisión 4 – Método de calibración

Qué decidí: usar calibración isotónica global, con un único calibrador aplicado a todos los solicitantes. No se calibró por grupo.

Qué descarté: sin calibrar, sigmoide global y calibración por grupo. La calibración por grupo usaría SEX para calibrar, lo que se aparta de la decisión de dejar SEX fuera como variable de auditoría, y fragmentaría el entrenamiento.

Por qué: el criterio fue menor log-loss en validación cruzada anidada dentro del 70 % (5 particiones externas; dentro de cada una, `CalibratedClassifierCV(cv=5)`). El isotónico obtuvo 0.426337, frente a 0.426558 del sigmoide y 0.427871 sin calibrar, y ganó también en Brier (0.133471) y ECE (0.004595). El AUC no se usó para elegir porque la calibración busca probabilidades correctas, no reordenar casos.

£Se usó la prueba para elegir? No. El 30 % de prueba se evaluó una sola vez después de la elección, solo como reporte (ECE isotónico en prueba 0.012525).

Qué pierdo: la isotónica es un escalón flexible que puede sobreajustar con muestras pequeñas y producir probabilidades repetidas; el sigmoide es más estable y suave. Además, un calibrador global garantiza $P(Y = 1 \mid S = s, G = g) \approx s$ solo en promedio: no corrige por sí mismo las diferencias de FPR/FNR entre grupos, que deben tratarse a nivel de umbral.

Evidencia: `04_calibracion.ipynb` y `resultados/04_comparacion_cv.csv`, `04_metricas_test.csv`, `04_metodo_calibracion.csv` y `04_tabla_grupos_despues.csv`.

Decisión 5 – Definición de equidad

Qué decidí: elegir **igual FPR** como definición de equidad.

Qué descarté: paridad demográfica, que iguala tasas de rechazo pero deja diferencias de errores de 1.76 y 1.26 puntos porcentuales en OOF, y paridad predictiva, que iguala la PPV pero deja diferencias de FPR de 10.96 puntos y de FNR de -7.51 en OOF. Igual FNR e igual FPR y FNR

no se descartaron por malas, sino porque en esta cuadrícula eligen el mismo par que igual FPR, así que no cambian el resultado.

Por qué: es la única diferencia entre grupos que el bootstrap de 05 muestra como real: el intervalo de FPR no contiene el cero (0.042289, IC 95 % [0.020183, 0.064465]) y el de FNR sí (−0.023922, IC 95 % [−0.064162, 0.015438]). El banco debería corregir primero la disparidad que la evidencia respalda. Además, igual FPR ataca la violación más visible del principio de tratar igual a quien paga: rechazar al 36.74 % de los hombres que no incumplieron frente al 32.51 % de las mujeres (prueba).

Qué pierdo: al igualar FPR se despriorizan otras definiciones. La tolerancia (0.01) y la cuadrícula (0.05–0.60, paso 0.01) son convenciones elegidas para el análisis; otra tolerancia podría dar otro par. La igualdad de FPR no garantiza igualdad de FNR o de PPV, y su cumplimiento debe vigilarse en carteras nuevas.

Evidencia: `06_intervencion.ipynb` y `resultados/06_comparativa_definiciones.csv`, `06_pares_umbrales_igual_fpr.csv` y `06_ganancia_vs_diferencia.png`.

Decisión 6 – Selección de umbrales

Qué decidí: usar dos umbrales, $t_H = 0.19$ y $t_M = 0.18$, elegidos con predicciones fuera de muestra (`cross_val_predict`, $cv = 5$) sobre el 70 %. El 30 % de prueba se usó solo para reportar el resultado, sin afinar los umbrales.

Qué descarté: mantener el umbral único 1/6, que conserva una diferencia de FPR de 4.23 puntos porcentuales que el bootstrap de 05 señaló como real, y elegir los umbrales sobre la prueba, lo que invalidaría la estimación del costo y de la equidad resultante.

Por qué: con igual FPR y tolerancia 0.01, el par $(0.19, 0.18)$ es el que maximiza la ganancia OOF entre los factibles (4697 unidades de G, frente a 4745 de la línea base). En prueba el costo no se distingue de cero: pérdida de 7 unidades de G, IC95 % $[-100, 116]$ (la magnitud puntual es 0.35 % de la ganancia base, 0.000778 por solicitante, pero no es distinguible del ruido con esta muestra). Los desempates se resolvieron de forma determinista: menor diferencia máxima, luego menor t_H y menor t_M.

Qué pierdo: usar umbrales distintos por grupo es una política explícita de trato diferenciado por atributo protegido y requiere justificación jurídica y de gobernanza; no basta con que sea técnicamente barata. Además, el par se eligió en una sola cuadrícula y tolerancia, y su estabilidad ante otras tolerancias o carteras nuevas debe vigilarse. La intervención no elimina la información de SEX: sigue siendo necesaria para auditar y para aplicar el umbral correcto.

Evidencia: `06_intervencion.ipynb` y `resultados/06_umbrales_elegidos.csv`, `06_top_pares_igual_fpr.csv`, `06_costo_equidad.csv` y `06_bootstrap_ic95.csv`.

Nota sobre el recuadro (e) de la teoría

Qué decidí: el recuadro "Tú decides" de `p1_teoria.tex` (inciso (e)) propone igual FPR con $(t_H, t_M) = (0.19, 0.18)$, acepta umbrales distintos por grupo con justificación y mantiene SEX fuera del modelo principal, en consistencia con la Decisión 3.

Por qué: resume los resultados de `06_intervencion.ipynb` y `07_sin_atributo.ipynb` (ver Decisiones 5 y 6) y los conecta con la imposibilidad del inciso (b); no introduce decisiones nuevas más allá de esas dos.

Qué pierdo: el recuadro es una síntesis de redacción e interpretación; su defensa oral se apoya en las Decisiones 5 y 6.

Estado: decisión aceptada y vigente.

Memorándum para el consejo del banco: igualdad de trato y costo de corregirla

El modelo de riesgo que el banco ya usa rechaza créditos con un puntaje de riesgo. Cuando se revisa por separado a hombres y mujeres, aparece una desigualdad clara: entre los clientes que sí habrían pagado, se rechaza al 36.74 % de los hombres y al 32.51 % de las mujeres. Esa diferencia de 4.23 puntos porcentuales se mantiene al repetir el análisis miles de veces con muestras alternativas, por lo que no parece producto de la casualidad. En cambio, la diferencia en el porcentaje de incumplidores que se aprueban (25.03 % en hombres frente a 27.42 % en mujeres) sí podría deberse al azar, y por eso no debería tratarse como una desigualdad probada. No es un problema de intención: con probabilidades bien calibradas, un mismo corte aplicado a todos produce resultados distintos cuando las tasas de incumplimiento de cada grupo son distintas (23.30 % en hombres y 21.34 % en mujeres en la muestra de prueba).

La corrección que se propone es ajustar ligeramente el corte según el grupo para igualar el porcentaje de rechazos entre quienes pagan. Con un corte de 0.19 para hombres y 0.18 para mujeres, elegidos solo con datos de entrenamiento, la diferencia en rechazos entre quienes pagan baja a 0.95 puntos en la muestra de prueba, un valor ya indistinguible del azar. Las demás brechas quedan también pequeñas (0.78 puntos en incumplidores aprobados, 1.61 en valor predictivo y 1.37 en tasa de rechazo): con tasas base de 23.3 % en hombres y 21.3 % en mujeres, la imposibilidad teórica de igualar todas las medidas a la vez es leve en este caso concreto, y casi todas las definiciones de trato justo se cumplen a la vez. Ojo: los intervalos de confianza de esas brechas posteriores son anchos (entre -0.012 y 0.031 para los rechazos de quienes pagan; entre -0.034 y 0.049 para los incumplidores aprobados), así que su compatibilidad con cero no prueba que las brechas hayan desaparecido, solo que con esta muestra ya no se distinguen del ruido. La ganancia pasa de 1984 a 1977 unidades: la pérdida de 7 unidades no se distingue de cero (IC95 % entre -100 y 116 unidades), así que no se puede afirmar que corregir cueste dinero con esta muestra. Otras reglas (igualar la tasa de rechazo o el valor predictivo) llegaron incluso a dar ganancias algo mayores que la línea base ($+11$ y $+35$ unidades), también dentro del ruido, pero dejan desigualdades de errores mayores y por eso no se recomiendan.

Hay compromisos que esta recomendación no elimina. Igualar un tipo de trato no iguala todos los demás, aunque en este caso las demás diferencias quedan pequeñas. Usar cortes distintos según el sexo es un trato diferenciado explícito: necesita fundamento jurídico y de gobierno, no solo eficacia técnica. Meter el sexo como dato del modelo tampoco resuelve nada: la ganancia subiría unos 35 unidades (IC95 % entre -36 y 100, dentro del ruido), pero la desigualdad entre grupos casi se duplica, y además otras variables del expediente permiten adivinar el sexo con una exactitud moderada. La recomendación práctica es, por tanto, mantener el modelo sin el sexo como entrada, aplicar los cortes ajustados con revisión jurídica, y vigilar periódicamente si la igualdad se sostiene.

Uso de asistentes de IA

Declaración de uso de asistentes de IA

Durante la preparación del Problema 1 y del Problema 2 el alumno utilizó asistentes de IA como apoyo, no como sustituto del estudio. En el Problema 2 los asistentes ayudaron en el andamiaje del código (módulos de descarga, kernels circulares en NumPy, SVR precalculados y ventana expansiva), en la redacción de los borradores de la teoría de kernels circulares (incisos (a)–(e)), de la bitácora y de la verificación de resultados, y en la revisión de consistencia de tablas, figuras y argumentos. En el Problema 1 los asistentes ayudaron en el andamiaje del código (módulos de descarga, preprocesamiento, calibración y auditoría por grupo), en la redacción de los borradores de la teoría (incisos (a)–(e)) y de esta bitácora, y en la revisión de consistencia de tablas, figuras y argumentos. Las decisiones de datos del Problema 1 con respuesta textual (códigos raros, PAY_*, SEX) fueron registradas por el alumno antes de ese apoyo; las decisiones de calibración, de equidad y las seis decisiones del Problema 2 redactadas con el asistente fueron revisadas y aceptadas por el alumno. El alumno revisa y estudia todo el material, reproduce el flujo con la semilla 223210350 y asume la defensa de las demostraciones, las tablas y las conclusiones. Ningún resultado se presenta sin que el código lo reproduzca desde los datos de UCI.

Problema 2

Problema 2 – Teoría de kernels circulares

Sea t un ángulo en el círculo, con periodo 2π, y sean $P_1 = 24$ y $P_2 = 7$ los periodos de la hora y del día de semana. La distancia circular $d(t, t')$ es el arco más corto entre ambos puntos, con valores en $[0, \pi]$: si $\Delta = |t - t'| \pmod{2\pi}$ es el recorrido en un sentido, entonces $d = \min(\Delta, 2\pi - \Delta)$.

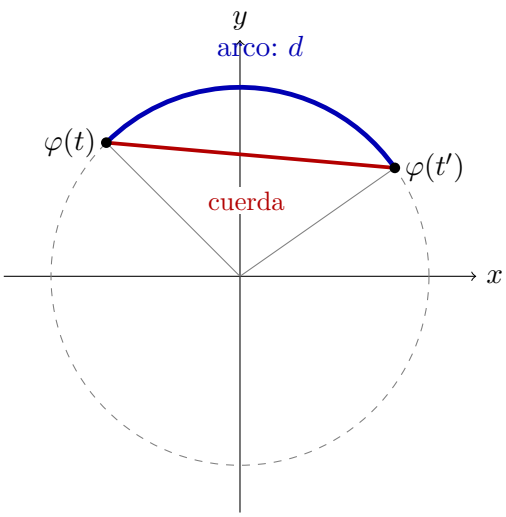
(a) La distancia circular y el mapa del coseno

Por definición, $d(23{:}00, 01{:}00) = \frac{2\pi \cdot 2}{24} = \frac{\pi}{6} \approx 0.524$: de las 23:00 a la 1:00 hay 2 horas de recorrido en un sentido ($\Delta = 2 \cdot (2\pi/24)$) y $2\pi - \Delta$ en el otro, y el arco más corto es $2 \cdot (2\pi/24) = \pi/6$; en cambio la diferencia de los números es $|23 - 1| = 22$. Análogamente, con sábado $= 6$ y lunes $= 1$ en $P = 7$, $\Delta = |6 - 1| \cdot (2\pi/7) = 5 \cdot (2\pi/7)$ y $2\pi - \Delta = 2 \cdot (2\pi/7)$, de modo que $d(\text{sábado}, \text{lunes}) = 2 \cdot \frac{2\pi}{7} = \frac{4\pi}{7} \approx 1.795$ (dos días de distancia, aunque los números difieren en 5).

Sea $\varphi(t) = (\cos t, \sin t)$. Entonces $\|\varphi(t)\|^2 = 1$ y

$$\|\varphi(t) - \varphi(t')\|^2 = \|\varphi(t)\|^2 + \|\varphi(t')\|^2 - 2\,\varphi(t) \cdot \varphi(t') = 2 - 2\cos(t - t'),$$

porque $\varphi(t) \cdot \varphi(t') = \cos t \cos t' + \sin t \sin t' = \cos(t - t')$ y cos es par y 2π-periódica, de modo que $\cos(t - t') = \cos d$ con d el arco más corto. La función $2 - 2\cos d$ es estrictamente creciente en $[0, \pi]$ porque su derivada es $2 \sin d > 0$ en $(0, \pi)$. Por eso la cuerda y el arco ordenan igual a los pares de puntos: si un par está más cerca que otro con una medida, también lo está con la otra.



El arco azul mide d (el ángulo, en el círculo unitario) y la cuerda roja mide $\|\varphi(t)-\varphi(t')\| = \sqrt{2-2\cos d}$, que es una función creciente de d.

(b) El kernel de von Mises es un kernel

Un kernel gaussiano sobre φ es $\exp\big(-\|\varphi(t)-\varphi(t')\|^2/(2\sigma^2)\big) = \exp\big(-(2-2\cos(t-t'))/(2\sigma^2)\big) = e^{-1/\sigma^2}\, e^{\cos(t-t')/\sigma^2}$, es decir, $k_\kappa(t,t') = e^{\kappa\cos(t-t')}$ multiplicado por la constante $e^{-\kappa} > 0$, con $\kappa = 1/\sigma^2$.

Por el inciso (a), $\cos(t-t') = \varphi(t)\cdot\varphi(t')$ es un kernel, con función de características $\varphi = (\cos, \sin)$. Expandimos la exponencial en serie de Taylor,

$$e^{\kappa\cos(t-t')} = \sum_{m=0}^{\infty} \frac{\kappa^m}{m!}\big(\cos(t-t')\big)^m,$$

y aplicamos (P1): cada potencia $\cos^m(t-t')$ es un producto de kernels, así que es un kernel; multiplicarla por $\kappa^m/m! > 0$ lo conserva, las sumas parciales son kernels, y el límite puntual de una sucesión de kernels es un kernel. Por tanto $e^{\kappa\cos(t-t')}$ es un kernel y, multiplicado por $e^{-\kappa} > 0$, k_κ también **es** un kernel.

(c) Por qué funciona el criterio de Fourier

La mitad fácil de (P2). Supongamos $k(t,t') = g(t-t') = a_0 + \sum_{n\geq 1} a_n \cos(n(t-t'))$ con $a_n \geq 0$ para todo n. Como $\cos(n\theta - n\theta') = \cos(n\theta)\cos(n\theta') + \sin(n\theta)\sin(n\theta')$, cada sumando $a_n\cos(n(t-t'))$ es el producto interno $\varphi_n(t)\cdot\varphi_n(t')$ con $\varphi_n(t) = \sqrt{a_n}\,(\cos nt, \sin nt)$, y el término constante a_0 es el kernel de $\varphi_0(t) = \sqrt{a_0}$. Así, cada sumando es un kernel, las sumas parciales lo son por (P1), y el límite puntual de las sumas parciales (la serie de Fourier de g, que converge a g al ser continua) también lo es por (P1). Luego k es un kernel.

La otra mitad (cómo la usaría). Si algún $a_n < 0$, entonces k **no** es un kernel, y hay que exhibir un vector que lo muestre. Se toma el conjunto equiespaciado $t_i = 2\pi i/N$, $i = 0, \ldots, N-1$, con $0 < n < N/2$, y el vector $v_i = \cos(nt_i)$. Usando $\cos(m(t_i - t_j)) = \cos(mt_i)\cos(mt_j) + \sin(mt_i)\sin(mt_j)$,

$$v^T K v = a_0\Big(\sum_i v_i\Big)^2 + \sum_{m\geq 1} a_m\Big[\Big(\sum_i v_i\cos(mt_i)\Big)^2 + \Big(\sum_i v_i\sin(mt_i)\Big)^2\Big].$$

Para $0 < n < N/2$ se cumple $\sum_i v_i = 0$, $\sum_i v_i \sin(mt_i) = 0$ para todo m y $\sum_i v_i \cos(mt_i) = N/2$ si $m \equiv \pm n \pmod N$ y 0 en otro caso. Por tanto

$$v^T K v = \frac{N^2}{4} \sum_{\substack{m \geq 1 \\ m \equiv \pm n \,(\mathrm{mod}\ N)}} a_m = \frac{N^2}{4}\big(a_n + a_{N-n} + a_{N+n} + a_{2N-n} + \cdots\big).$$

Los coeficientes distintos de a_n son sus *alias* en la malla de N puntos. Como g es continua y suave a trozos, $\sum_m |a_m| < \infty$, así que los alias tienden a 0 cuando N crece; entonces, si $a_n < 0$, para N suficientemente grande $v^T K v < 0$ y k no es un kernel. Con una malla pequeña los alias pueden compensar a a_n, y esto explica lo que ocurre con k_I en siete puntos (inciso (d)).

(d) Ningún candidato es un kernel

Con $g(t) = k(d = |t|)$ sobre $[-\pi, \pi]$, los coeficientes de Fourier $a_n = \frac{2}{\pi}\int_0^\pi g(t)\cos nt\, dt$ $(n \geq 1)$ tienen forma cerrada. Para $k_I = e^{-d^2/2}$ (completando el cuadrado en la integral),

$$a_n^{(I)} = \sqrt{\tfrac{2}{\pi}}\; e^{-n^2/2}\ \mathrm{Re}\ \mathrm{erf}\Big(\tfrac{\pi - in}{\sqrt{2}}\Big).$$

Para $k_{II} = \max(0, 1 - d^2/4)$, que se anula para $d \geq 2$, integrando por partes,

$$a_0^{(II)} = \frac{4}{3\pi}, \qquad a_n^{(II)} = \frac{2}{\pi}\Big[-\frac{\cos 2n}{n^2} + \frac{\sin 2n}{2n^3}\Big] \quad (n \geq 1).$$

Estas fórmulas coinciden con la cuadratura numérica de la libreta 01 (primeros 40 coeficientes y gráficas):

- $k_I = \exp(-d^2/2)$ **no es un kernel.** El primer coeficiente negativo es $a_4 \approx -3.19 \times 10^{-4}$ (también son negativos $a_6, a_8, \ldots$, todos los pares). Contraejemplo: las 24 horas $t_i = 2\pi i/24$ y el vector $v_i = \cos(2\pi \cdot 4\, i/24)$, $i = 0, \ldots, 23$ (con $n = 4$). La computadora da $v^T K v \approx -0.0583$ con $v^T v = 12$; el menor valor propio de la matriz de las 24 horas es $\lambda_{\min} \approx -0.00505$. En el inciso (c), $\frac{N^2}{4} a_4 = 144\, a_4 \approx -0.0459$ es el término dominante, y el valor exacto incluye sus alias $a_{20}, a_{28}, \ldots$.
- $k_{II} = \max(0, 1 - d^2/4)$ **no es un kernel.** El primer coeficiente negativo es $a_3 \approx -0.0712$ (hay más negativos: $a_6, a_7, a_9, \ldots$). Contraejemplo: las 24 horas y $v_i = \cos(2\pi \cdot 3\, i/24)$ (con $n = 3$), que da $v^T K v \approx -10.07$ con $v^T v = 12$ ($144\, a_3 \approx -10.25$ más alias) y $\lambda_{\min} \approx -0.839$.

Un conjunto de puntos que engaña. Con los **siete días** ($t_i = 2\pi i/7$), la matriz de k_I *sí* resulta semidefinida positiva, con $\lambda_{\min} \approx +0.0326 > 0$. Es una matriz circulante y su valor propio de frecuencia 3 es $\frac{7}{2}(a_3 + a_4 + a_{10} + a_{11} + \cdots)$: el coeficiente negativo $a_4 \approx -3.19 \times 10^{-4}$ cae como alias sobre $a_3 \approx +0.00966$, que lo domina. Esto **no contradice** nada: la definición de kernel exige que K sea semidefinida positiva para **todos** los conjuntos finitos de puntos, y basta uno que falle (las 24 horas) para que k_I no lo sea; que un conjunto concreto no revele el problema es compatible con que no lo sea. Para k_{II} los siete días sí lo revelan ($\lambda_{\min} \approx -0.197$). Por eso en la práctica (M4) se usan kernels circulares válidos y no estos candidatos.

(e) Varias variables a la vez: suma y producto

Sean k_1 en las horas y k_2 en las temperaturas, con funciones de características ϕ_1 y ϕ_2.

- **Suma.** Con $\phi_+(h,t) = (\phi_1(h), \phi_2(t))$ (concatenación),

  $$\phi_+(h,t)\cdot\phi_+(h',t') = \phi_1(h)\cdot\phi_1(h') + \phi_2(t)\cdot\phi_2(t') = k_1(h,h') + k_2(t,t') = k_+\big((h,t),(h',t')\big),$$

  así que k_+ es un kernel. La SVM predice $f(h,t) = \sum_i \alpha_i\, k_+\big((h_i,t_i),(h,t)\big) + b = \underbrace{\sum_i \alpha_i k_1(h_i,h)}_{f_1(h)} + \underbrace{\sum_i \alpha_i k_2(t_i,t)}_{f_2(t)} + b$. Es **aditiva**: el efecto de la hora, $f_1(h)$, no depende de la temperatura.

- **Producto.** Con $\phi_\times(h,t) = \phi_1(h)\otimes\phi_2(t)$ se tiene $\langle \phi_1\otimes\phi_2, \phi_1'\otimes\phi_2'\rangle = \langle\phi_1,\phi_1'\rangle\langle\phi_2,\phi_2'\rangle = k_\times$, consistente con (P1). Ahora $f(h,t) = \sum_i \alpha_i\, k_1(h_i,h)\, k_2(t_i,t) + b$: el peso que recibe cada $k_1(h_i,h)$ es $\alpha_i k_2(t_i,t)$, que depende de t. Por tanto **sí hay interacción**: el efecto de la hora puede cambiar con la temperatura.

Por eso la estructura elegida en la práctica, $(k_{hr}\cdot k_{wd}) + k_{rbf}$, impone interacción entre hora y día de la semana (el patrón horario de los días laborales difiere del de los fines de semana) y deja un efecto aditivo para las demás variables estandarizadas.

Bitácora de decisiones – Problema 2

Cada decisión registra qué se decidió, qué se descartó, por qué y con qué evidencia. Todas fueron redactadas por el asistente con evidencia propia y aceptadas por el alumno; quedan como decisiones vigentes del trabajo.

Decisión 1 – Esquema de validación

Qué decidí: ventana expansiva con 4 particiones sobre la muestra ordenada por (dteday, hr), con bloques de 500 horas: entrena 0:1000 y valida 1000:1500; entrena 0:1500 y valida 1500:2000; entrena 0:2000 y valida 2000:2500; entrena 0:2500 y valida 2500:3000, entrenando siempre con horas anteriores a las de validación.

Qué descarté: un split aleatorio 80/20 (mezcla futuro en el entrenamiento y no refleja el uso real) y una sola partición temporal (solo 500 horas de validación, alta varianza).

Por qué: en demanda temporal solo es honesto validar hacia el futuro; con 4 particiones se tienen 2000 horas de validación en momentos distintos y el entrenamiento crece (1000, 1500, 2000, 2500), reflejando cómo mejora el modelo con más datos. Evidencia: las fechas impresas en `02_decisiones_p2` (p. ej., P1: entrena 2011-01-01 a 2011-07-31 y valida 2011-07-31 a 2011-11-19) y `resultados/p2_02_particiones.csv`.

Qué pierdo: los bloques cortan dentro de un día, las particiones no son independientes (entrenamientos solapados) y no se evalúa extrapolación estacional completa porque la muestra termina el 2012-09-30.

Decisión 2 – Combinación de kernels

Qué decidí: la combinación **(iii)** $(k_{hr}\cdot k_{wd}) + k_{rbf}$, con von Mises para hora y día (kappas en rejilla) y RBF para las demás variables estandarizadas.

Qué descarté: (i) la suma pura $k_{hr} + k_{wd} + k_{rbf}$ (fuerza la misma forma horaria todos los días) y (ii) el producto total $k_{hr}\cdot k_{wd}\cdot k_{rbf}$ (obliga también al clima a interactuar con hora y día).

Por qué: las gráficas de registradas medias por hora separando `workingday` muestran formas distintas (doble pico laboral frente a máximo al mediodía en fin de semana): hay interacción hora $\times$ día. La validación lo confirma: RMSLE medio (iii) 0.556 frente a (ii) 0.623 y (i) 0.720. Evidencia: `resultados/p2_02_registrado_por_hr.png`, `p2_02_registrado_por_weekday.png` y `p2_02_comparacion_kernels.csv`.

Qué pierdo: (iii) asume el efecto del clima aditivo sobre la interacción hora-día; una interacción clima $\times$ hora por bandas podría capturar más, a costa de más parámetros.

Decisión 3 – Objetivo logarítmico y métrica RMSLE

Qué decidí: trabajar con $\log 1\mathrm{p}(\texttt{registered})$ y elegir modelos por **RMSLE** (RMSE y MAE se reportan en 04 como contexto).

Qué descarté: el objetivo crudo con RMSE global.

Por qué: errar 20 bicicletas a las 3:00 (nivel ≈ 18) no cuesta lo mismo que a las 18:00 (nivel ≈ 188): el error absoluto crece con el nivel (RMSE crudo de 10.5 en madrugada a 58.2 en la tarde), mientras que RMSLE es mucho más estable entre franjas y en validación el modelo en log obtiene RMSLE global 0.404 frente a 0.570 del modelo en crudo. Evidencia: `resultados/p2_02_error_por_franja.csv`.

Qué pierdo: RMSLE subestima errores absolutos grandes en horas pico, y al retransformar con expm1 hay sesgo de retransformación (la media del log no es el log de la media).

Decisión 4 – Kernel circular válido elegido

Qué decidí: von Mises $\exp(\kappa(\cos d - 1))$ para hr y para $weekday$, con kappas independientes en rejilla $\{1, 3\}$ (en 03 ganaron $\kappa_{hr} = 3$, $\kappa_{wd} = 1$).

Qué descarté: $\exp(-d/\ell)$, $\max(0, 1 - d/2)$ y $\pi^2/6 - \pi d/2 + d^2/4$ (los cuatro son válidos según la verificación, pero no admiten un parámetro de concentración tan interpretable como κ y son menos flexibles para picos horarios).

Por qué: es el kernel circular estándar, κ controla el ancho de forma interpretable y es el que justifica la teoría (Taylor de la exponencial). Evidencia: `resultados/p2_01_coeficientes.csv` (los cuatro sin coeficientes negativos) y `p2_01_eigenvalores.csv`.

Qué pierdo: un único κ por dimensión no captura formas asimétricas intra-día (subida rápida, bajada lenta).

Decisión 5 – workingday, weathersit y yr

Qué decidí: sacar **`workingday`** de la parte RBF y conservar **`weathersit`** (ordinal numérico) y **`yr`** (binaria) en la parte RBF, junto a season, mnth, holiday, temp, atemp, hum y windspeed.

Qué descarté: incluir `workingday` como variable extra.

Por qué: `workingday` vale 1 exactamente si $weekday \in 1, \ldots, 5$ y `holiday` $= 0$ (verificado en las 3000/3000 filas): es función exacta de `weekday` y `holiday`, que ya entran por el kernel de periodo 7 y por la parte RBF. `weathersit` discrimina el nivel (161.9, 141.6, 91.8, 22.0) y `yr` captura el crecimiento interanual (117.5 a 194.5). Evidencia: sección 4 de `02_decisiones_p2`.

Qué pierdo: `holiday` queda como binaria en RBF, así que el efecto de festivos puntuales (Navidad) se captura solo parcialmente.

Decisión 6 – Estandarización de "otras" y entrada del HGB

Qué decidí: estandarizar las "otras" **una sola vez con la muestra completa de 3000 horas** (para que la matriz M4 de 3000×3000 se calcule una vez y se rebane) y dar al HGB **todas las columnas de entrada** (incluida `workingday`), porque es la referencia sin restricción de kernels.

Qué descarté: estandarizar por partición (impide la matriz única precalculada que pide el enunciado para M4) y limitar el HGB a las variables de los SVR.

Por qué: la fuga por estandarizar solo covariables (sin el objetivo) es mínima y despreciable frente a las diferencias entre modelos (RMSLE 0.44 frente a 0.60–1.00). El HGB, sin kernels, se beneficia de ver `workingday` explícito. Evidencia: secciones 1 de `03_modelos_p2` y 04.

Qué pierdo: un ligero optimismo en validación por la estandarización global, del orden del error de estimación con 1000–2500 puntos.

Nota sobre kernels no válidos (evidencia, no decisión)

K_I y K_{II} no son kernels: $a_4 \approx -3.19 \times 10^{-4}$ y $a_3 \approx -0.0712$, con $\lambda_{\text{mín}}(24\text{h}) \approx -0.00505$ y -0.839. M4 con ellos (03, sección 5) da $\lambda_{\text{mín}} = -0.247$ y -45.4 en la matriz de entrenamiento, sin advertencias de libsvm, y RMSLE de validación 0.552 y 25.45 (con todos los puntos como vectores de soporte en el caso k_{II}) frente a 0.439 del M4 válido: el dual pierde convexidad, óptimo global y garantía de convergencia de SMO.